

李阔

✉ 2353113@tongji.edu.cn · ☎ (+86) 17643088018 · GitHub: Zlatanwic

🎓 教育背景

同济大学，计算机科学与技术系，数据科学与大数据技术（本科） 2023 – 2027（预计）

GPA: 90.51/100, 4.56/5.0, 专业排名: 2/40

- 英语: IELTS 7.0, CET-6 571

🔍 研究兴趣

研究方向主要集中于 ML Sys / AI Infrastructure, 关注从高性能算子、编译运行时到分布式训练与在线服务的全栈系统优化, 具体包括:

- **大模型推理与服务系统**: 面向高并发、长上下文和多租户工作负载, 研究请求调度、KV Cache 管理与分层存储、Prefill-Decode 协同、故障容错, 以及系统与模型的协同设计。
- **分布式训练与通信优化**: 关注数据并行、张量并行、流水线并行和专家并行等训练策略, 以及通信计算重叠、集合通信优化和大规模训练系统的可扩展性与可靠性。
- **GPU 算子与深度学习编译**: 关注 CUDA 高性能编程、算子融合、Megakernel、持久化执行、自动调优和高性能算子生成, 并探索 Triton、TileLang 等编程与编译框架。
- **Agent 与异构 AI 基础设施**: 研究 Agent Harness 自进化、工具调用编排、技能编译与运行时优化, 以及面向 RISC-V 等异构硬件的端侧模型推理系统。
- 正在探索多模态、强化学习以及具身智能系统相关的方向

🔬 科研经历

- **同济大学图像融合实验室** 【2025.09 – 2026.01】
受唐伟老师指导, 以第一作者身份完成 ACM Multimedia 2026 论文投稿; 论文进入 Rebuttal 阶段, Rebuttal 前审稿评分为 4/4/3/2/2, 最终未被接收。
- **独立研究经历** 【2026.02 – 2026.04】
以独立作者身份投稿 ICIC 2026, 论文被接收为 Oral Presentation。目前在上海交通大学陈博老师指导下, 对该工作进行进一步扩展与优化, 计划投稿 CCF-A 类会议。
- **上海交通大学先进网络研究所** 【2026.05 – 至今】
受陈博老师指导, 面向多请求 LLM Serving 场景, 开展语义优先级调度与 KV Cache 存储管理的协同设计研究。
- **上海交通大学 IPADS 实验室** 【2026.05 – 2026.07】
受冯二虎老师指导, 参与 SkVM (SOSP 2026) 的后续扩展, 对系统效果与性能进行优化。
- **南京大学 LANDS 实验室** 【2026.05 – 2026.07】
受宦成颖老师指导, 基于 MNN 开展 RISC-V 端侧推理链路优化。相关论文正在撰写, 本人为第三作者, 在学生作者中排名第一, 计划投稿 HPCA 2027。

📁 代表性项目经历

SemServe: 语义优先级与 kv cache 存储精度的 co-design 系统 2026

论文在写 Python / PyTorch / Transformers / Qwen2.5-3B / Llama-3.2-3B

- 前身是我作为独立作者 oral 中稿 ccf-c 会议 ICIC 2026 的工作, 然后之后跟着上海交通大学陈博老师扩展优化这篇工作, 目标为 ccf-a 类会议。
- 语义打分采用 auto-tuning 方法, 拟合一个函数, 优化目标为 SLO, 离线搜索, 在线计算
- 将语义优先级和 MLFQ 直接映射, 最高优先级队列以 fp16 精度存储, 次优先级以 int8 存储, 第三优先级 offload 到 cpu。

- 为 4 个 Agent Adapter (pi / claude-code / opencode / hermes) 实现面向 Terminal-Bench v2.1 的容器化执行模式；
- 在 AOT 编译器的 pass3 中引入 **DLP / ILP / TLP** 三级并行分类并对 ILP 类工具调用实施并行分发；
- 在 jit-optimazition 阶段引入多角色智能体优化，并与多轮智能体优化做对比

📁 投稿经历

- 以第一作者完成一篇 CCF-A 会议投稿论文 (ACMMM 2026 图像处理方向)。
- 以独立作者完成投稿 ICIC 2026 并被接收 (KV cache management 方向)
- 以第三作者投稿 (学生作者里的第一) HPCA 2027

其他系统项目

Rust 操作系统内核

Rust / RISC-V / QEMU

- 使用 Rust 面向 RISC-V 架构实现教学型操作系统内核，完成 Boot、Trap、系统调用、进程管理、虚拟内存和文件系统等基础模块，并使用 QEMU 与 GDB 调试。

Mini-GFS 分布式文件系统

Go / RPC / Distributed Storage

- 使用 Go 实现包含 Master、ChunkServer 和 Client 的简化版 GFS，支持文件分块、读写、元数据管理、Chunk 副本维护、心跳检测及节点失效处理。

基于 Chord 的分布式哈希环

Go / Distributed Systems / RPC

- 实现基于一致性哈希的分布式键值存储原型，支持节点动态加入与退出、Finger Table 路由、数据迁移及周期性 Stabilization。

Rust MCP Server

Rust / MCP / Async Runtime

- 使用 Rust 实现支持工具 Schema、请求解析、异步执行和错误处理的 MCP Server，相关项目已被收录至 Awesome-MCP-ZH。

⚙️ 技能

- 编程语言：Rust, C/C++, Python, Go
- 传统系统：Linux, 分布式系统, concurrency, RISC-V
- AI 系统：CUDA C++, PyTorch, vLLM, NCCL, GPUDirect RDMA
- coding agent 使用：熟练使用 claude code,codex 等工具，并且配置了自己的 skill, mcp, hook, rules 等 harness

🏆 荣誉与竞赛

国家一等奖（队内一顺位），全球校园人工智能算法大赛算法挑战赛道	2025.12
国际银奖，国际基因工程机器大赛（iGEM）	2025.10