

李阔

✉ 2353113@tongji.edu.cn · ☎ (+86) 17643088018 · GitHub: Zlatanwic

🎓 教育背景

清华大学，计算机科学与技术系，博士研究生 (Incoming) 2027 (预计入学)

- 指导教师：武永卫教授、章明星老师

同济大学，计算机科学与技术系，数据科学与大数据技术 (本科) 2023 – 2027 (预计)

最终专业排名：4/40

- 英语：IELTS 7.0, CET-6 571

🔍 研究兴趣

研究方向主要集中于 ML Sys / AI Infrastructure，关注从高性能算子、编译运行时到分布式训练与在线服务的全栈系统优化，具体包括：

- **大模型推理与服务系统**：面向高并发、长上下文和多租户工作负载，研究请求调度、KV Cache 管理与分层存储、Prefill-Decode 协同、故障容错，以及系统与模型的协同设计。
- **分布式训练与通信优化**：关注数据并行、张量并行、流水线并行和专家并行等训练策略，以及通信计算重叠、集合通信优化和大规模训练系统的可扩展性与可靠性。
- **GPU 算子与深度学习编译**：关注 CUDA 高性能编程、算子融合、Megakernel、持久化执行、自动调优和高性能算子生成，并探索 Triton、TileLang 等编程与编译框架。
- **Agent 与异构 AI 基础设施**：研究 Agent Harness 自进化、工具调用编排、技能编译与运行时优化，以及面向 RISC-V 等异构硬件的端侧模型推理系统。
- 正在探索多模态、强化学习以及具身智能系统相关的方向

🔬 科研经历

- **上海交通大学先进网络研究所** [2026.05 – 至今]
受 陈博老师指导，面向多请求 LLM Serving 场景，开展语义优先级调度与 KV Cache 存储管理的协同设计研究。
- **上海交通大学 IPADS 实验室** [2026.05 – 2026.07]
受 冯二虎老师 指导，参与 SkVM (SOSP 2026) 的后续扩展，对系统效果与性能进行优化。

📁 代表性项目经历

SemServe：语义优先级与 kv cache 存储精度的 co-design 系统 2026

论文在写 Python / PyTorch / Transformers / Qwen2.5-3B / Llama-3.2-3B

- 前身是我作为独立作者 oral 中稿 ccf-c 会议 ICIC 2026 的工作，然后之后跟着上海交通大学陈博老师扩展优化这篇工作，目标为 ccf-a 类会议。
- 语义打分采用 auto-tuning 方法，拟合一个函数，优化目标为 SLO，离线搜索，在线计算
- 将语义优先级和 MLFQ 直接映射，最高优先级队列以 fp16 精度存储，次优先级以 int8 存储，第三优先级 offload 到 cpu。

SkVM：面向异构 LLM 与 Agent Harness 的技能编译与运行时系统 持续迭代中

SJTU-IPADS 实验室项目，论文已中稿 SOSP2026 TypeScript / Bun / Docker / LLM Agent

- 为 4 个 Agent Adapter (pi / claude-code / opencode / hermes) 实现面向 Terminal-Bench v2.1 的容器化执行模式；
- 在 AOT 编译器的 pass3 中引入 DLP / ILP / TLP 三级并行分类并对 ILP 类工具调用实施并行分发；
- 在 jit-optimization 阶段引入多角色智能体优化，并与多轮智能体优化做对比

📖 学术论文

- [1] **Kuo Li**, Wei Tang. “S3Fusion: CLIP-Guided Multi-focus Image Fusion via Semantic-Structural Synergism.” *ACM MM 2026*. **Rejected**. (第一作者, 图像处理方向)
- [2] **Kuo Li**. “SieveKV: Semantic Multi-Signal Eviction for Long-Context Retrieval.” *ICIC 2026*. **Accepted**. (独立作者, KV Cache Management 方向)
- [3] Chengying Huan, Yudong Liu, **Kuo Li**, Jing Zhang, Bo He, Junjie Xu, Jiageng Yu, Fangxin Liu, Jie Zhang, Chen Tian. “RVWeaver: Memory-Form and Microarchitecture Co-Adaptive Data-Path Planning for Portable Machine Learning Execution.” *ccf-a 2027*. **Underreview**. (第三作者、学生第一作者, RISC-V 架构端侧推理优化方向)

其他系统项目

Rust 操作系统内核

Rust / RISC-V / QEMU

- 使用 Rust 面向 RISC-V 架构实现教学型操作系统内核, 完成 Boot、Trap、系统调用、进程管理、虚拟内存和文件系统等基础模块, 并使用 QEMU 与 GDB 调试。

Mini-GFS 分布式文件系统

Go / RPC / Distributed Storage

- 使用 Go 实现包含 Master、ChunkServer 和 Client 的简化版 GFS, 支持文件分块、读写、元数据管理、Chunk 副本维护、心跳检测及节点失效处理。

基于 Chord 的分布式哈希环

Go / Distributed Systems / RPC

- 实现基于一致性哈希的分布式键值存储原型, 支持节点动态加入与退出、Finger Table 路由、数据迁移及周期性 Stabilization。

Rust MCP Server

Rust / MCP / Async Runtime

- 使用 Rust 实现支持工具 Schema、请求解析、异步执行和错误处理的 MCP Server, 相关项目已被收录至 Awesome-MCP-ZH。

⚙️ 技能

- 编程语言: Rust, C/C++, Python, Go
- 传统系统: Linux, 分布式系统, concurrency, RISC-V
- AI 系统: CUDA C++, PyTorch, vLLM, NCCL, GPUDirect RDMA
- coding agent 使用: 熟练使用 claude code, codex 等工具, 并且配置了自己的 skill, mcp, hook, rules 等 harness

🏆 荣誉与竞赛

国家一等奖 (队内一顺位), 全球校园人工智能算法大赛算法挑战赛道	2025.12
国际银奖, 国际基因工程机器大赛 (iGEM)	2025.10